

MATRIZ DE COSTOS Y OPTIMIZACIÓN — DARK IMPORTS

Ecosistema de automatización IA — Make + Airtable + OpenAI + Telegram

1. Objetivo de la estrategia de costos

La arquitectura busca mantener una respuesta comercial rápida y de bajo costo, utilizando el modelo de IA únicamente para interpretar la consulta y generar la respuesta. Los datos de inventario se recuperan desde Airtable, evitando enviar información innecesaria al modelo y reduciendo tokens.

Criterio principal: usar un modelo económico para consultas simples y reservar modelos más costosos para casos que realmente requieran razonamiento complejo.

2. Matriz de decisión por tarea

Tarea	Tecnología / modelo	Motivo	Nivel de costo
Recepción de consulta	Telegram + Make	No requiere IA; solo captura y transporte de datos.	Muy bajo
Búsqueda de producto y stock	Airtable Search Records	La base de datos contiene el inventario y evita usar tokens para buscar datos.	Muy bajo
Interpretación de lenguaje natural	OpenAI — modelo económico / mini	Ideal para detectar intención, producto y disponibilidad en consultas comerciales simples.	Bajo
Generación de respuesta	OpenAI — modelo económico / mini	Las respuestas son cortas y estructuradas; no necesitan un modelo premium.	Bajo
Casos complejos o ambiguos	Modelo avanzado de OpenAI, solo si es necesario	Se utiliza como escalamiento cuando la consulta requiere mayor razonamiento.	Medio / alto
Registro y actualización	Airtable + Make	No requiere procesamiento IA.	Muy bajo
Envío de respuesta	Telegram	Canal directo y automatizado.	Bajo

3. Modelo recomendado para el flujo

Para el escenario actual de Dark Imports se recomienda utilizar GPT-4o-mini o el modelo mini equivalente disponible en la cuenta como modelo principal. La tarea consiste principalmente en clasificación de intención, extracción de producto y redacción de mensajes breves.

Característica	Modelo económico / mini	Modelo avanzado
Consultas simples	Excelente	Sobrecualificado
Clasificación de intención	Excelente	Excelente
Respuesta comercial corta	Excelente	Excelente
Razonamiento complejo	Adecuado	Mejor
Costo por operación	Menor	Mayor
Uso recomendado	Modelo por defecto	Solo escalamiento

4. Estrategias concretas de ahorro

Estrategia	Aplicación	Beneficio
Limitar tokens de salida	Configurar una respuesta corta y un máximo de tokens acorde al caso.	Evita pagar por respuestas innecesariamente largas.
Prompt compacto	Enviar solo instrucciones necesarias y variables relevantes.	Reduce tokens de entrada.
Airtable como memoria	Consultar stock desde la base antes de llamar a IA.	Evita utilizar IA para recuperar datos estructurados.
Modelo mini por defecto	Usarlo en consultas comerciales normales.	Reduce costo por interacción.
Escalamiento selectivo	Enviar al modelo avanzado solo consultas ambiguas o complejas.	Evita utilizar el modelo caro en todas las conversaciones.
Evitar duplicados	Validar ID de mensaje / estado antes de procesar nuevamente.	Reduce operaciones innecesarias en Make, Airtable y OpenAI.
Batch para procesos masivos	Aplicarlo únicamente si se incorporan cargas masivas de consultas.	Puede reducir costo en procesos de gran volumen.

5. Estimación comparativa

La siguiente estimación es una matriz relativa para justificar la arquitectura. Los precios reales de APIs pueden cambiar según proveedor, modelo, tokens y fecha; por eso se expresa el ahorro como proporción y no como un precio fijo.

Escenario	Costo relativo	Impacto	Evaluación
Modelo avanzado en todas las consultas	100%	Máximo consumo de IA	No recomendado
Modelo mini en todas las consultas	≈ 10-30%*	Mucho menor consumo	Recomendado
Mini + escalamiento selectivo	≈ 15-35%*	Mantiene bajo costo y permite resolver casos complejos	Mejor equilibrio
Sin IA + reglas fijas	≈ 0-10%*	Muy barato pero pierde interpretación de lenguaje natural	No cumple el objetivo completo

*Los porcentajes son rangos orientativos de arquitectura, no una cotización del proveedor. El costo final depende del volumen, tokens de entrada/salida y modelo vigente.

6. Política de selección automática

El flujo puede implementar una política simple de escalamiento:

1. Consulta normal → modelo mini.
2. Producto encontrado y respuesta clara → modelo mini + respuesta.
3. Consulta ambigua, reclamo, negociación o caso fuera del catálogo → escalar al modelo avanzado o derivar a humano.
4. Error de API → registrar el error y utilizar la ruta de recuperación correspondiente.

7. Justificación económica para la rúbrica

La arquitectura evita utilizar un modelo premium para cada mensaje. El inventario permanece en Airtable y solamente se envía a OpenAI el contexto necesario. Para consultas comerciales cortas se utiliza un modelo mini, con un límite de tokens de salida. Los casos complejos pueden escalarse de forma selectiva. Esta combinación reduce el costo promedio por conversación manteniendo la calidad donde realmente es necesaria.

8. Conclusión

La decisión recomendada es OpenAI modelo mini como opción por defecto + escalamiento selectivo a un modelo avanzado. Make se mantiene como orquestador, Airtable como memoria/inventario y Telegram como canal de salida. El ahorro se obtiene principalmente por selección de modelo, reducción de tokens, reutilización de datos estructurados y prevención de ejecuciones duplicadas.